

```
In [9]: 1 import argparse
2 import logging
3 import os
4 import jieba
5 import math
6 import requests
7 import wiki as w
8 from gensim.models.fasttext import FastText
9 from gensim.models.word2vec import Word2Vec
10 from tqdm import tqdm
11 import matplotlib.pyplot as plt
12 import numpy as np
13 from sklearn.decomposition import PCA
```

D:\Anaconda3\lib\site-packages\gensim\utils.py:1197: UserWarning: detected Windows; aliasing chunkize to chunkize\_serial  
warnings.warn("detected Windows; aliasing chunkize to chunkize\_serial")

```
In [10]: 1 from gensim.models import KeyedVectors
2 fasttext_300d_model = 'pre-trained/cc.zh.300/cc.zh.300.vec'
3 wordvectors_index = KeyedVectors.load_word2vec_format(fasttext_300d_model)
```

D:\Anaconda3\lib\site-packages\smart\_open\smart\_open\_lib.py:398: UserWarning: This function is deprecated, use smart\_open.open instead. See the migration notes for details: [https://github.com/RaRe-Technologies/smart\\_open/blob/master/README.rst#migrating-to-the-new-open-function](https://github.com/RaRe-Technologies/smart_open/blob/master/README.rst#migrating-to-the-new-open-function)  
'See the migration notes for details: %s' % \_MIGRATION\_NOTES\_URL

```
In [11]: 1 wordvectors_index.most_similar('我')
```

```
Out[11]: [('你', 0.7679306864738464),
('他', 0.7081897258758545),
('想', 0.7019494771957397),
('她', 0.6555640697479248),
('要', 0.6327636241912842),
('真的', 0.6318696737289429),
('就', 0.6110949516296387),
('知道', 0.6072597503662189),
('大家', 0.5957611799240112),
('叫我', 0.5952475070953369)]
```

```
In [12]: 1 vec = wordvectors_index['我']
2 print(vec)
3 print('The Length of Vector:', len(vec))
```

```
-1.680e-02  7.100e-02  4.490e-02  -1.471e-01  4.000e-04  -4.250e-02
-3.530e-02  -5.910e-02  -2.190e-02  9.900e-03  2.067e-01  -9.030e-02
-6.020e-02  2.170e-02  -1.490e-02  1.361e-01  -1.749e-01  2.330e-02
5.110e-02  -5.310e-02  1.406e-01  -6.600e-03  -2.100e-03  -1.155e-01
1.702e-01  3.890e-02  3.020e-02  1.132e-01  7.450e-02  -2.140e-02
5.630e-02  2.810e-02  -3.800e-03  -4.350e-02  1.548e-01  -6.520e-02
6.060e-02  5.900e-02  -4.400e-02  -8.500e-03  1.950e-02  7.940e-02
1.300e-02  1.414e-01  9.690e-02  7.490e-02  -1.249e-01  1.498e-01
-9.950e-02  -2.530e-02  2.080e-02  4.300e-02  -3.140e-02  -8.150e-02
3.820e-02  -2.242e-01  -3.080e-02  8.130e-02  -3.800e-03  4.540e-02
7.580e-02  6.230e-02  2.690e-02  3.122e-01  -1.950e-02  3.190e-02
2.670e-02  3.210e-02  1.710e-02  -4.370e-02  4.320e-02  1.357e-01
1.169e-01  7.180e-02  1.390e-02  2.910e-02  -3.730e-02  7.900e-03
-2.280e-02  2.640e-02  1.611e-01  -6.830e-02  3.900e-02  -5.760e-02
-3.260e-02  1.364e-01  -2.990e-02  6.710e-02  4.230e-02  -6.890e-02
-4.540e-02  -1.358e-01  -6.200e-02  8.740e-02  -2.710e-02  -1.040e-01
1.010e-02  -1.542e-01  -9.660e-02  -5.950e-02  -5.250e-02  3.290e-02
```

```
In [5]: 1 import pandas as pd
2 df = pd.read_csv('wikidata.csv')
3 df
```

```
Out[5]:
```

	id	url	title	text
0	13	<a href="https://zh.wikipedia.org/wiki/?curid=13">https://zh.wikipedia.org/wiki/?curid=13</a>	數學	數學是利用符號語言研究數量、結構、變化以及空間等概念的一門學科，從某種角度看屬於形式科學的一...
1	18	<a href="https://zh.wikipedia.org/wiki/?curid=18">https://zh.wikipedia.org/wiki/?curid=18</a>	哲學	哲學是研究普遍的、根本的問題的學科，包括存在、知識、價值、理智、心靈、語言等其他...
2	21	<a href="https://zh.wikipedia.org/wiki/?curid=21">https://zh.wikipedia.org/wiki/?curid=21</a>	文學	文學在最廣泛的意義上，是任何單一的書面作品。更嚴格地說，文學寫作被認為是一種藝術形式，或被認...
3	22	<a href="https://zh.wikipedia.org/wiki/?curid=22">https://zh.wikipedia.org/wiki/?curid=22</a>	歷史	歷史是指人類社會過去的事件和行動，以及對這些事件行為有系統的記錄、詮釋和研究。歷史可提供今人...
4	25	<a href="https://zh.wikipedia.org/wiki/?curid=25">https://zh.wikipedia.org/wiki/?curid=25</a>	電腦科學	電腦科學是系統性研究資訊與計算的理論基礎以及它們在電腦系統中如何與應用的實用技術的學科。它...

```
In [6]: 1 df['text'][0]
```

```
Out[6]: 數學是利用符號語言研究數量、結構、變化以及空間等概念的一門學科，從某種角度看屬於形式科學的一種。數學透過抽象化和邏輯推理的使用，由計數、計算、量度和對物體形狀及運動的觀察而產生。數學家們拓展這些概念，為了公式化新的猜想以及從選定的公理及定義中建立起嚴謹推理出的定理。'
```

```
In [7]: 1 import jieba
2 import numpy as np
3 jieba.set_dictionary('dict.txt.big')
```

```
In [13]: 1 def stopwordslist(filepath):
2 stopwords = [line.strip() for line in open(filepath, 'r', encoding='utf-8').readlines()]
3 return stopwords
```

```
In [53]: 1 def seg_sentence(sentence):
2 sentence_segged = jieba.cut(sentence.strip())
3 stopwords = stopwordslist('stops.txt') # 加載停用詞的路徑
4 outstr = ''
5 for word in sentence_segged:
6 if word not in stopwords:
7 if word != '\t':
8 outstr += word
9 outstr += " " #再次組合或【帶空格】的串
10 return outstr
```

```
In [55]: 1 inputs = open('input.txt', 'r', encoding = 'utf-8')
2 outputs = open('output.txt', 'w')
3
4 for line in inputs:
5 line_seg = seg_sentence(line) # 這裏的返回值是字符串
6 outputs.write(line_seg + '\n')
7
8 outputs.close()
9 inputs.close()
```

```
In [91]: 1 f = open('output.txt')
2 text = []
3 for line in f:
4 line = line.strip('\n').strip(' ')
5 text.append(line)
6 print(text)
7 print(text[0].split(' '))
```

```
['來到 北京 清華大學', '來到 網易 杭研 大廈', '小明 碩士 畢業 中國科學院 計算所 後 日本京都大學 深造']
```

['來到', '北京', '清華大學']

```
In [96]: 1 import pandas as pd
2 final = []
3 for i in range(len(text)):
4     x = text[i].split(' ')
5     final.append(x)
6     df_new = pd.DataFrame(final)
7 df_new
```

Out[96]:

	0	1	2	3	4	5	6	7
0	來到	北京	清華大學	None	None	None	None	None
1	來到	網易	杭研	大廠	None	None	None	None
2	小明	碩士	畢業	中國科學院	計算所	後	日本京都大學	深造

In [102]: 1 df\_new.iat[0,3]

In [106]: 1 # 第一列元素個數
2 df\_new.count(axis=1)[0]

Out[106]: 3

In [123]: 1 df\_new.count(axis=1)[2]

Out[123]: 8

```
In [135]: 1 for a in range(0,3):
2     for i in range(df_new.count(axis=1)[a]):
3         getword = df_new.iat[a,i]
4         print('Word:',getword)
5         sim = wordvectors_index.most_similar(getword)
6         print(sim,'\n')
7         vec = wordvectors_index[getword]
8         #print(vec)
```

Word: 來到

[('們到', 0.680351197719574), ('離開', 0.6726597547531128), ('來到', 0.6725727915763855), ('會到', 0.64908766746521), ('帶到', 0.6413955688476562), ('到達', 0.6270354986190796), ('抵達', 0.6244625449180603), ('拜訪', 0.6237394213676453), ('見到', 0.623458981513977), ('剛到', 0.6193416118621826)]

Word: 北京

[('北京市', 0.695327639579773), ('上海', 0.6890406012535095), ('天津', 0.6707611680030823), ('海淀', 0.6531842947006226), ('丰台', 0.6383175849914551), ('南京', 0.634671688079834), ('深圳', 0.6265233159065247), ('廣州', 0.6191778779029846), ('瑞志', 0.6073142290115356), ('成都', 0.6062750816345215)]

Word: 清華大學

[('國立清華大學', 0.5424829721450806), ('清華', 0.5316276550292969), ('語言所', 0.5306745767593384), ('大學醫學院', 0.5273380279541016), ('本校與', 0.5210415720939636), ('臺北校區', 0.5204195976257324), ('大學教員', 0.5161640644073486), ('學新竹', 0.5138156414031982), ('學報', 0.5105436444282532), ('學之', 0.5099607110023499)]

Word: 來到

[('們到', 0.680351197719574), ('離開', 0.6726597547531128), ('來到', 0.6725727915763855), ('會到', 0.64908766746521), ('帶到', 0.6413955688476562), ('到達', 0.6270354986190796), ('抵達', 0.6244625449180603), ('拜訪', 0.6237394213676453), ('見到', 0.623458981513977), ('剛到', 0.6193416118621826)]

Word: 網易

[('聞客戶端', 0.5876361131668091), ('騰訊網', 0.5696948170661926), ('科技訊', 0.5581492781639099), ('騰訊', 0.5550828576087952), ('東方網', 0.5459731221199036), ('張朝陽', 0.5439282655715942), ('曹國偉', 0.538353443145752), ('黑馬', 0.5373672246932983), ('央視網', 0.5314080119132996), ('疑文謄', 0.5296161770820618)]

Word: 杭研

[('易盾', 0.711364209651947), ('沃趣', 0.6763855218887329), ('邱跃鹏', 0.6757369637489319), ('舜飞', 0.6741166114807129), ('云信', 0.67271888256073), ('陈本峰', 0.6661608219146729), ('商诤', 0.6632800102233887), ('热厂', 0.6563276052474976), ('聆听华', 0.6546007394790649), ('听云', 0.6530683040618896)]

Word: 大廠

[('廈', 0.7920844554901123), ('大樓', 0.679903507232666), ('廈及', 0.6486297249794006), ('廈寧', 0.6374667286872864), ('盈量', 0.6272530555725098), ('飛遠', 0.6174845695495605), ('廈和', 0.6097941398620605), ('廈後', 0.6090506911277771), ('廈內', 0.607770323753569), ('宿H5', 0.6075724959373474)]

Word: 小明

[('小华', 0.6519417762756348), ('小亮', 0.6270813941955566), ('小军', 0.6093065142631531), ('小刚', 0.598380088061523), ('小丽', 0.5637282729148865), ('明叁', 0.5430482625961304), ('情景二', 0.5329578518867493), ('小芳', 0.5278083086013794), ('小明家', 0.496097594499588), ('小杰', 0.4890586733818054)]

Word: 碩士

[('碩士學', 0.7465630769729614), ('學位', 0.6896508932113647), ('哲學博士', 0.6655946969985962), ('碩士班', 0.6558831334114075), ('博士學', 0.6482836604118347), ('雙碩士', 0.6465559601783752), ('碩士畢業', 0.6463962197303772), ('雙學士', 0.6345175504684448), ('學素', 0.634415864944458), ('學士', 0.6317906379699707)]

Word: 畢業

[('學畢業', 0.7099490761756897), ('大學畢業', 0.7092317342758179), ('畢業生', 0.6711447238922119), ('剛從學', 0.6586110591888428), ('毕业', 0.6297016739845276), ('我畢業', 0.6236075162887573), ('中學畢業', 0.6210829019546509), ('從畢業', 0.6187918186187744), ('從入學', 0.6176089644432068), ('大學讀', 0.6081340909004211)]

Word: 中國科學院

[('马街乡', 0.0), ('區徵信社', 0.0), ('M化', 0.0), ('微博給', 0.0), ('2016百万', 0.0), ('X宽', 0.0), ('讀萬幾', 0.0), ('種落', 0.0), ('天絲入', 0.0), ('功課好', 0.0)]

Word: 計算所

[('马街乡', 0.0), ('區徵信社', 0.0), ('M化', 0.0), ('微博給', 0.0), ('2016百万', 0.0), ('X宽', 0.0), ('讀萬幾', 0.0), ('種落', 0.0), ('天絲入', 0.0), ('功課好', 0.0)]

Word: 後

[('之後', 0.8636327385902405), ('以後', 0.7380192279815674), ('后', 0.7275388836860657), ('隨即', 0.715072512626648), ('後退', 0.6953732967376709), ('後將', 0.6875186562538147), ('後會', 0.6811140179634094), ('過後', 0.6801283359527588), ('並', 0.6712456345558167), ('開始', 0.6707596778869629)]

Word: 日本京都大學

[('马街乡', 0.0), ('區徵信社', 0.0), ('M化', 0.0), ('微博給', 0.0), ('2016百万', 0.0), ('X宽', 0.0), ('讀萬幾', 0.0), ('種落', 0.0), ('天絲入', 0.0), ('功課好', 0.0)]

Word: 深造

[('进修', 0.6674454212188721), ('升進', 0.6207159757614136), ('進修', 0.6014084815979004), ('攻读', 0.5910628437995911), ('读博', 0.5838335752487183), ('读研', 0.568256676197052), ('求学', 0.5608309507369995), ('求學', 0.5483633875846863), ('攻讀', 0.5272366404533386), ('升读', 0.5261021256446838)]

In [ ]:

1